

UNIVERSIDAD DEL VALLE DE GUATEMALA

Facultad de Ingeniería

Data Science – LYNETTE GARCIA PEREZ

Sección 10



Laboratorio 2

Javier Chen, 22153

Gustavo Cruz, 22779

Introducción:

El objetivo principal de este laboratorio es diseñar, entrenar y evaluar modelos LSTM sobre al menos dos de las series previamente utilizadas, comparando sus resultados con los modelos tradicionales aplicados anteriormente. Para ello, se implementaron múltiples configuraciones de redes LSTM, afinando sus hiperparámetros con el propósito de mejorar su desempeño predictivo.

Dado que las series temporales suelen presentar patrones secuenciales complejos, los modelos LSTM son adecuados por su capacidad para aprender dependencias a largo plazo en los datos. A lo largo del laboratorio, se desarrollaron y analizaron distintos modelos, seleccionando aquellos que ofrecieran mejores resultados.

Información de los Datos:

Para el desarrollo de este laboratorio se utilizarán tres conjuntos de datos oficiales proporcionados por el Ministerio de Energía y Minas (MEM) de Guatemala:

- Consumo de combustibles: Registra el volumen mensual en barriles desde enero del 2000 hasta mayo del 2025 para gasolina súper, regular, diésel (y diésel LS desde 2018) y gas licuado.
- Importación de combustibles: Contiene datos mensuales desde enero del 2001 hasta mayo del 2025, también en barriles de 42 galones.
- Precios promedios al consumidor final en Ciudad Capital: Incluye precios diarios desde el 1 de enero de 2021 hasta el 13 de julio de 2025, en quetzales por galón para las gasolinas y el diésel, y por cilindro de 25 lbs para el gas licuado.

Modelos LSTM:

Importación de diésel:

División de datos:

- Entrenamiento: enero 2001 – junio 2022 (258 observaciones)
- Prueba: julio 2022 – mayo 2025 (35 observaciones)

-Modelo 1 – LSTM_Diesel_1

- Ventana temporal: 20 meses
- Unidades LSTM: 64
- Capas LSTM: 2
- Dropout: 0.3
- Learning rate: 0.0001
- Épocas máximas: 200
- Batch size: 12

Métricas obtenidas:


- MAE: 139,190.12
- RMSE: 174,750.58
- MAPE: 9.62%

-Modelo 2 – LSTM_Diesel_2

- Ventana temporal: 24 meses
- Unidades LSTM: 95
- Capas LSTM: 3
- Dropout: 0.25
- Learning rate: 0.00007
- Épocas máximas: 300
- Batch size: 16

Métricas obtenidas:

- MAE: 112,843.42
- RMSE: 133,717.02
- MAPE: 8.14%



Consumo de gasolina superior:

División de datos:

- Entrenamiento: enero 2000 – junio 2022 (270 observaciones)
- Prueba: julio 2022 – mayo 2025 (35 observaciones)

-Modelo 1 – LSTM_Gasolina_1

- Ventana temporal: 3 meses
- Unidades LSTM: 120
- Capas LSTM: 3
- Dropout: 0.5
- Learning rate: 0.0005
- Épocas máximas: 250
- Batch size: 3

Métricas obtenidas:


- MAE: 40,163.60
- RMSE: 49,681.33
- MAPE: 6.08%

-Modelo 2 – LSTM_Gasolina_2

- Ventana temporal: 1 mes
- Unidades LSTM: 64
- Capas LSTM: 2
- Dropout: 0.2
- Learning rate: 0.001
- Épocas máximas: 100
- Batch size: 2

Métricas obtenidas:

- MAE: 50,299.57
- RMSE: 61,609.64
- MAPE: 7.56%



Selección del mejor modelo:

Importación de Diesel:

Modelo seleccionado: LSTM_Diesel_2

Métrica	LSTM_Diesel_1	LSTM_Diesel_2
MAE	139,190.12	112,843.42
RMSE	174,750.58	133,717.02
MAPE	9.62%	8.14%

Justificación:

- El modelo LSTM_Diesel_2 redujo el error absoluto medio (MAE) en aproximadamente 26,000 unidades, lo cual representa una mejora significativa en la precisión.

- También se observó una reducción sustancial en el RMSE, lo que indica que las predicciones están más cerca del valor real.
- El MAPE inferior sugiere que el modelo es más robusto, lo cual es crucial cuando los valores fluctúan a lo largo del tiempo.
- Además, la configuración más compleja del modelo (mayor ventana temporal, más unidades y capas) le permitió capturar patrones más largos en los datos.

Consumo de Gasolina superior:

Modelo seleccionado: LSTM_Gasolina_1

Métrica	LSTM_Gasolina_2	LSTM_Gasolina_1
MAE	50,299.57	40,163.60
RMSE	61,609.64	49,681.33
MAPE	7.56%	6.08%

Justificación:

- LSTM_Gasolina_1 obtuvo mejores resultados en todas las métricas evaluadas, reflejando una mayor precisión y menor variabilidad en sus predicciones.
- Aunque su configuración utilizó una ventana temporal más corta (3 meses), la combinación de una arquitectura más profunda y mayor número de unidades LSTM permitió que el modelo capturara adecuadamente la dinámica reciente de la serie.
- El MAPE del 6.08% indica una alta capacidad de predicción incluso con valores relativamente pequeños, lo cual es favorable para este tipo de datos.

Comparación con modelos del laboratorio anterior:

Importación de Diesel:

Modelo	MAE	RMSE	MAPE
ARIMA (0,1,1) (Lab1)	158,922.36	191,750.78	12.13%
LSTM_Diesel_2 (Lab2)	112,843.42	133,717.02	8.14%

Mejor modelo: LSTM_Diesel_2

Justificación:

- Supera al ARIMA en las tres métricas: menor MAE, menor RMSE y menor MAPE.
- El modelo LSTM tiene mayor capacidad para capturar patrones no lineales y dependencias a largo plazo en series temporales complejas como las de importación de combustibles.

Gasolina superior:

Modelo	MAPE	MAE	RMSE
Prophet (Lab 1)	7.94%	51,057.71	61,431.55
LSTM_Gasolina_1 (Lab2)	14.43%	97,223.72	108,047.11

Mejor Modelo: Prophet

- El modelo Prophet supera por mucho al LSTM en todas las métricas: más de 40% menos error absoluto y cuadrático, y un MAPE casi a la mitad.
- Esto indica que, en esta serie, el modelo clásico Prophet fue capaz de capturar mejor la estructura de la serie, posiblemente debido a una estacionalidad más clara o una menor complejidad temporal que favorece un modelo aditivo.

Conclusiones:

- Para la serie de importación de diésel, el modelo LSTM_Diesel_2 superó significativamente al modelo ARIMA utilizado anteriormente. El LSTM presentó menores errores absolutos (MAE y RMSE), así como un menor error porcentual (MAPE), destacando su capacidad para modelar relaciones no lineales y patrones de largo plazo. Esta mejora evidencia que, en series con alta complejidad y volumen, las redes neuronales recurrentes pueden superar a los enfoques estadísticos tradicionales.
- Por otro lado, para la serie de consumo de gasolina superior, el modelo Prophet del laboratorio anterior tuvo un mejor desempeño que el mejor modelo LSTM (LSTM_Gasolina_1). Prophet logró métricas más bajas en todas las categorías, especialmente en MAPE, lo que indica una mayor precisión relativa. Esta diferencia sugiere que, para series con estacionalidades bien definidas y menor ruido estructural, los modelos clásicos aditivos como Prophet pueden ser más adecuados que las redes LSTM, que requieren una mayor cantidad de datos y ajuste fino para generalizar correctamente.
- En resumen, los resultados muestran que no existe un único modelo óptimo para todas las series de tiempo. La elección del modelo más apropiado depende del comportamiento de la serie, su complejidad estructural y el objetivo de predicción. Los modelos LSTM demostraron su fortaleza en series complejas como la importación de diésel, mientras que Prophet resultó más eficaz en series con patrones estacionales más claros y comportamiento más estable como el consumo de gasolina superior. Este laboratorio resalta la importancia de evaluar distintas técnicas y ajustar modelos cuidadosamente para obtener predicciones confiables y robustas.